

2026-05-13

Idea


- **老 idea**：host-side KV checkpoint 做 fault tolerance —— engine 死了能从 checkpoint 恢复。问题是 failure 概率太低，benefit 撑不起一篇 paper。
- **新 idea**：同一份 KV checkpoint 用来支持 cheap preempt —— scheduler 可以便宜地踢正在 decode 的长上下文请求。**机制完全一样，使用场景换了。**

Design

KV checkpoint mechanism

What	per-block delta（只存新稳定的 block）
When	每 16 token 一存（一个 vLLM KV block）
Where	L1 host pinned（同 engine）+ L2 shared host store（跨 engine 可读）


Healthy-load tax：+~30 ms TTFT P50，throughput diff < 0.5%。



Slack-based preempt picker

- **slack** = 离 SLO miss 的 wall-clock 时间
- 每个 scheduler step：running 队列里挑 slack 最大的 (victim)，waiting 队列里挑 slack 最小的 (head)
- preempt 条件（三个 AND）： $gap > \delta + replay_cost \cdot victim$ 有 `checkpoint · cooldown` 过了

Slack picker · pick laziest tail, admit most urgent head



Method

Setup

Hardware	2× A6000 (+ L40S portability)
Model	Qwen2.5-7B-Instruct fp16, <code>max_model_len 32K</code>
Workloads	RULER 16K (主打) · ShareGPT (don't break)
Arrivals	Poisson · 3-tier QoS (tight / normal / loose)
SLO tiers	baseline P95 × {2×, 3×, 6×}
Baselines	<code>vllm_fcfs</code> · <code>reroute_no_ckpt</code> · <code>ours_no_picker</code> · <code>ours</code>
Seeds	3 per config

Experiments

	Measures	Status
E_M1	SLO attainment vs QPS	A6000 done · L40S 在跑
E_M4	picker ablation (+ <code>ours_no_picker</code>)	这周排上
E_D1	failover gap (FT use case, bonus)	RULER 16K demo 跑通

Submission

- 目标：APSys 2026 Workshop

- **DDL**：5/20（周三）